




World Models: cosa sono, perché servono, come costruirli

Dai modelli mentali umani alle architetture ibride per l'IA generativa



Aipermind Research

March 2026



1. Che cos'è un World Model

Un sistema viene definito *World Model* (WM) quando è in grado di comprendere le dinamiche di un determinato “mondo”, calcolarne lo stato successivo e utilizzare questa capacità per supportare il processo decisionale e la pianificazione.

Questa definizione lascia intenzionalmente aperti alcuni concetti chiave: *mondo*, *dinamica*, *stato*. Una declinazione intuitiva di questi termini può essere la seguente:

Mondo: la realtà tridimensionale che abitiamo. **Dinamica:** le leggi della fisica che lo governano. **Stato:** un istante del mondo, definito da un insieme di grandezze — energia potenziale e cinetica, condizioni termodinamiche, massa, temperatura, ma anche colori, riflessi, forme, composizioni chimiche. **Stato successivo:** il risultato causale di una trasformazione governata da leggi precise (fisiche, termodinamiche, biochimiche), in generale esito di un bilancio energetico e di vincoli che determinano ciò che è possibile e ciò che non lo è. **Processo decisionale:** per esempio, stabilire la traiettoria di un taxi sulla base della destinazione del passeggero, della topografia della città, delle condizioni atmosferiche e del traffico — oppure orchestrare un'intera flotta.

Il concetto di World Model non nasce con il deep learning. Deriva dalla psicologia cognitiva: Kenneth Craik, negli anni '40, e Philip Johnson-Laird, negli anni '80, hanno teorizzato che la mente umana funziona costruendo *modelli in scala ridotta della realtà* per simulare mentalmente scenari e prendere decisioni. La nostra mente è, a tutti gli effetti, un World Model — anzi, ne ospita diversi contemporaneamente.

Anche in ambito informatico, i tradizionali simulatori fisici basati su regole matematiche esplicite sono World Model deterministici a tutti gli effetti. La novità del momento attuale non sta nel concetto, ma nel tentativo di replicare questa capacità all'interno di sistemi di IA generativa.

2. Perché i Large Language Model non sono World Model

Le grandi reti neurali che molti di noi utilizzano quotidianamente — i Large Language Model (LLM) — non predicono lo *stato* successivo di un sistema: predicono il *token* successivo. Non incorporano alcuna definizione formale di “stato” né una comprensione strutturale del mondo. I nessi causali che producono sono *inferiti per imitazione* dei nessi causali validati dagli esseri umani durante il processo di addestramento, ma non sono validati direttamente dal modello. Che è, appunto, un modello linguistico.



Quando abbiamo l'impressione che un agente AI “si sia fatto un'idea” della realtà, ciò che sta accadendo è che il sistema ci restituisce i nostri discorsi — che a loro volta sono un'emanazione dei nostri modelli mentali. Ma c'è una differenza fondamentale: quando noi utilizziamo i nostri modelli mentali, non lo facciamo per imitazione e ricombinazione testuale. Accediamo a una rappresentazione latente che si è formata attraverso l'esperienza, non attraverso la mera esposizione a testi.

La maggior parte di chi usa gli LLM per generare testo non percepisce questa limitazione. Chi si occupa di robotica, simulazione o sistemi predittivi, invece, ne è perfettamente al corrente.

3. Le implicazioni pratiche

Qualunque sistema software che incorpori una componente generativa basata su LLM ne incorpora anche le fragilità strutturali. Se l'obiettivo è confinato all'elaborazione del linguaggio — produzione di testi, counseling generico, confezionamento di contenuti — il rischio è relativamente basso.

Ma se lo scopo è effettuare previsioni o supportare decisioni critiche, anche un complesso sistema multi-agentico rimane troppo fragile. Dal punto di vista progettuale, un sistema predittivo costruito senza coscienza di questi limiti è un sistema “incosciente”: sviluppato ignorando i vincoli fondamentali degli strumenti che impiega.

4. Come trasferire un World Model in un sistema generativo

Esistono oggi due famiglie di approcci principali.

4.1 World Model puramente generativi (approccio Soft)

Si tratta di architetture pre-addestrate, concettualmente diverse dagli LLM. Invece di predire il prossimo token, il loro obiettivo è predire il prossimo *stato* del sistema. Utilizzano vettori ad altissima dimensionalità per apprendere da enormi quantità di dati (video, testi, interazioni con l'ambiente) e costruiscono una rappresentazione interna e astratta delle dinamiche del mondo, senza che nessuno le abbia esplicitate. Un po' come un bambino che sa prevedere la traiettoria di una palla senza aver studiato la fisica.

Le architetture JEPA proposte da Yann LeCun sono un esempio paradigmatico di questo approccio: non generano immagini, pixel o testi, ma prevedono trasformazioni future nello spazio latente. Ad oggi, tuttavia, queste architetture **non sono ancora stabili né utilizzabili in produzione.**



4.2 World Model ibridi (approccio Soft–Hard)

Fortunatamente, le architetture puramente generative non costituiscono l'unico approccio. Esistono approcci ibridi che, pur richiedendo un significativo lavoro di formalizzazione e orchestrazione, sono già praticabili. In letteratura, rimangono ad oggi i più accreditati, perché garantiscono maggiore *osservabilità e controllo*.

Un World Model ibrido “Soft–Hard” richiede tre componenti:

Una componente generativa pre-addestrata (Soft), che viene usata per generare ipotesi e scenari.

Una rappresentazione latente del World Model, che include gli elementi dello spazio, le relazioni tra di essi, le leggi della “dinamica”, gli stati, i passaggi tra stati e il tipo di previsioni effettuabili.

Una componente software esterna (Hard), che vincola la generazione al World Model, garantendo coerenza e affidabilità.

5. Il concetto di “latente”

Il termine “latente” (dal latino *latens*, nascosto) indica ciò che esiste e agisce sotto la superficie senza essere direttamente visibile. Nel machine learning, i vettori latenti sono rappresentazioni compresse dei legami semantici che la rete apprende autonomamente. Ma il concetto di rappresentazione latente non appartiene solo alle reti neurali: è pervasivo nei nostri modelli mentali e nei nostri sistemi concettuali.

Alcuni esempi dal dominio dell'innovazione. Un **modello di business**, con i suoi sotto-componenti che interagiscono secondo determinate regole, è una rappresentazione latente del modo in cui un complesso sistema socio-economico funziona. Dominare questo modello permette di distinguere il sostenibile dal non sostenibile, il desiderabile dal non desiderabile.

Il concetto di **mercato**, con le sue dinamiche, è una rappresentazione latente del modo in cui il sistema economico si organizza per progredire. Dominarlo permette di distinguere tra una buona innovazione e una bella invenzione, tra utile e superfluo.

Il concetto di **sistema cognitivo** è una rappresentazione latente — ancora per larga parte inesplorata — del modo in cui il cervello funziona e i comportamenti si manifestano. Dominarlo, per quanto possibile, permette di distinguere tra una risposta affidabile e un'allucinazione ben confezionata.



Un **modello di innovazione** è un World Model in cui queste rappresentazioni a loro volta interagiscono secondo regole già codificate, e il cui dominio permette di distinguere tra vero progresso e mero teatrino.

È possibile trasformare la conoscenza di questi modelli latenti in regole semantiche e relazionali, incorporandole nell'architettura del sistema attraverso un approccio ibrido neurosimbolico. L'enforcement di queste relazioni orchestra la componente generativa, realizzando un sistema di simulazione che agisce coerentemente con i vincoli causali del dominio di riferimento.

6. Sintesi e conclusione

Ricapitolando: gli LLM non sono World Model, e questo li rende rischiosi quando applicati a compiti predittivi o decisionali. I World Model puramente generativi (come le architetture JEPA) sono promettenti ma ancora irrisolti. È però già possibile costruire architetture ibride che combinano la capacità generativa degli LLM con l'affidabilità e la robustezza di un WM.

La costruzione di sistemi predittivi e decisionali affidabili passa oggi attraverso tre principi:

Framework neurosimbolici (Soft + Hard). La rete neurale immagina scenari e fornisce conoscenza di base; la componente algoritmica esterna — contenente la logica di dominio e le regole del sistema — orchestra lo stato successivo, impedendo allucinazioni logiche.

Simulatori orientati al dominio. La fusione tra capacità generativa e codifica esplicita di modelli economici, cognitivi e di mercato produce ambienti simulati in cui è possibile testare l'impatto di nuove ipotesi a costo zero, con una fedeltà impossibile per un chatbot testuale.

Il valore del dominio umano. In attesa che le architetture puramente causali e latenti siano in grado di apprendere autonomamente le leggi dell'economia e dell'innovazione, il vantaggio competitivo risiede nel *design dell'infrastruttura di modelli interconnessi*. Inserire modelli di innovazione e di business come griglie “normative” trasforma un motore probabilistico in un World Model ibrido controllabile, capace di supportare decisioni strategiche con solide fondamenta causali.

Sistemi come Aipermind non si limitano a generare testo: utilizzano il testo come interfaccia per manipolare un modello del mondo deterministico, ponendo le basi per una pianificazione strategica assistita dall'IA che sia *affidabile* oltre che generativa.



Riferimenti bibliografici

Chen, Z., & Zhu, T. (2026, January 21). *From generative engines to actionable simulators: the imperative of physical grounding in world models*. arXiv.Org.

<https://arxiv.org/abs/2601.15533>

Ding, J., Zhang, Y., Shang, Y., Zhang, Y., Zong, Z., Feng, J., Yuan, Y., Su, H., Li, N., Sukiennik, N., Xu, F., & Li, Y. (2025). Understanding world or predicting future? A comprehensive survey of world models. *ACM Computing Surveys*, 58(3), 1–38.

<https://doi.org/10.1145/3746449>

Li, M. (2025). From large language models to large action models: Reasoning and planning with physical world knowledge. *Proceedings of the AAAI Conference on Artificial Intelligence*, 39(27), 28714–28714. <https://doi.org/10.1609/aaai.v39i27.35109>

Nam, H., Lidec, Q. L., Maes, L., LeCun, Y., & Balestriero, R. (2026, February 11).

Causal-JEPA: Learning world models through object-level latent interventions.

arXiv.Org. <https://arxiv.org/abs/2602.11389>

Worden, R. (2026, January 25). *AI and world models*. arXiv.Org.

<https://arxiv.org/abs/2601.17796>

More references on request hello@aipermind.com